

用于高光谱图像去噪的局部-长距离感知网络

刘力源

摘要

由于高光谱图像 (Hyperspectral Image, HSI) 的成像机制与环境因素会产生噪声, 因此去噪是高光谱图像预处理的关键步骤, 长距离空间光谱相关性建模能够有效对高光谱图像进行去噪, 但其复杂度较高。现有的去噪方法存在局限性, 如基于卷积神经网络的方法难以满足更高性能需求。Transformer 的自注意力机制复杂度高, 对于空间光谱建模不理想。因此本文提出基于 Mamba 的高效内存模型用于高光谱图像的去噪, 其核心是空间光谱连续扫描 (SSCS), 该方法通过特定扫描顺序生成序列, 利用双向 SSM 探索长距离空间光谱依赖关系。同时由于该扫描方式局部存在遗忘问题, 本文采用注意力状态空间对其进行改进, 提出一种局部-长距离感知网络, 在 ICVL 数据集上的实验结果表明, 该方法具有更好的去噪性能。

关键词: 高光谱图像; 图像去噪; Mamba; 注意力状态空间; 深度学习

1 引言

高光谱图像 (Hyperspectral Image, HSI) 是一种包含丰富光谱信息的图像类型, 能够记录每个像素在多个连续光谱波段上的反射或辐射强度。与只包含红、绿、蓝三个波段的光谱信息的普通彩色图像不同, 高光谱图像的光谱分辨率更高, 可以涵盖数百甚至上千个窄波段。这使得高光谱图像能够捕获物质的细微光谱特征, 实现传统成像无法达到的精细分析。因此它被广泛应用于材料识别 [23]、物体检测 [6, 21]、物体跟踪 [4, 12]、变化检测 [19] 与环境保护 [5] 等领域中。高光谱图像的示意图如图 1 所示:

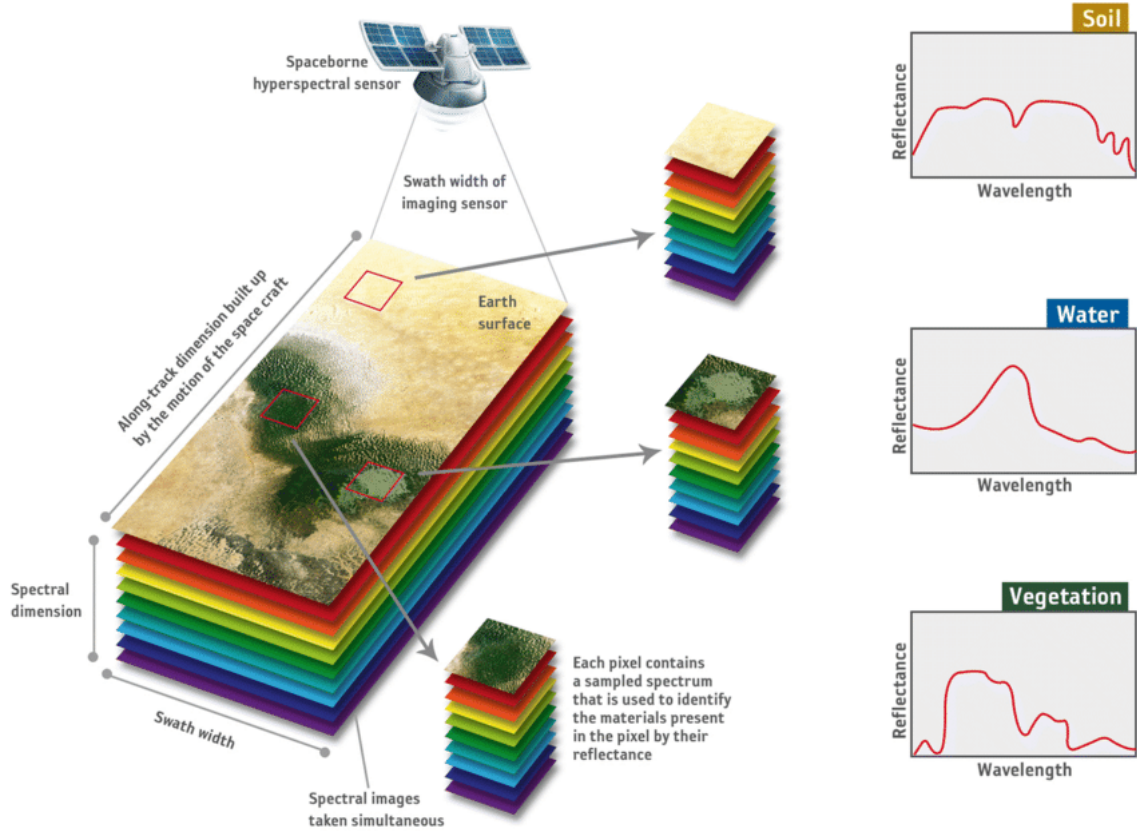


图 1. 高光谱图像示意图

而噪声是 HSI 中不可避免的问题，由多种因素引起，例如曝光时间不足、成像平台的机械振动、大气扰动、光子计数中的随机误差以及其他内在和外因素 [14, 15]，因此降噪是提高图像质量并提高 HSI 实际应用的重要预处理阶段。

近年来，由于深度学习 (DL) 强大的表征能力，高光谱图像去噪方法从传统的手工方法转向了基于深度学习的方法。得益于自注意力机制对长距离空间和光谱相关性的建模能力，基于 Transformer 的方法 [3] 展现出比基于 CNN 的方法更强的性能。然而，由于自注意力机制的复杂度为 $O(n^2)$ ，这些方法通常会结合多个模块分别探索空间和光谱域，旨在减少标记的长度并避免冗余信息。

源自控制系统的状态空间模型 (SSM) [10]，因其处理长序列时的线性复杂度而受到关注。Mamba [9] 作为一种具有优化选择性的 SSM，由于其线性复杂度，在计算机视觉任务中展现出显著优势，这对图像中的长距离建模具有良好作用。与卷积或自注意力操作不同，Mamba 需要将多维数据按特定顺序排列成 1-D 序列，而不恰当的扫描可能导致在展平序列中空间上接近的像素相距甚远，从而引发局部像素遗忘的问题。鉴于图像的非顺序特性，双向扫描 [27] 已被引入以取代单向扫描方案，使 Mamba 更适合图像处理。之字形扫描 [13] 通过在排序过程中纳入空间连续扫描进一步改进了 Mamba，确保了数据的连续性。

在高光谱图像中，每个像素的光谱值不仅取决于其在空间域中的相邻像素，还取决于不同光谱波段中的对应像素。高光谱图像建模的独特性质给建模带来了重大挑战，使得 Mamba 在高光谱图像去噪中的应用相对未被充分探索。Liu 等人 [18] 引入了一种基于 SSM 的方法来挖掘高光谱图像中的双向长距离空间依赖关系，但忽略了长距离光谱依赖关系。

在本文中，引入了一种用于高光谱图像去噪的空间光谱模型 U-Mamba (SSUMamba) [7]。SSUMamba 具有 U 形架构，并利用空间光谱连续扫描方案 (SSCS) 来挖掘长距离空间光谱依

赖关系。基于已字形扫描，SSCS 采用六种双向扫描方案为后续的 SSM 生成多个空间光谱连续序列，从而有效地捕捉长距离空间光谱相关性。但由于其本质为顺序扫描的 1D 序列，虽然能够捕获长距离的特征但会存在无法有效捕获局部上下文导致局部遗忘问题，因此本文引入注意力状态空间模块 [11] 对局部特征进行捕获，将该网络命名为局部-长距离感知网络。在建模长距离空间光谱依赖关系时的线性复杂度、SSCS 扫描方案以及改进的局部捕获，局部-长距离感知网络方法与基于 CNN 和基于 Transformer 的方法相比，展现出更优的去噪潜力。

2 相关工作

在本节中，简要回顾在高光谱图像去噪工作上的相关方法及技术细节。

2.1 传统去噪方法

传统的去噪的方法利用稀疏和低秩表示来描述用于去噪的干净高光谱图像的物理特性。Zhang 等 [26] 引入了 low-TR-rank regularizer 和稀疏 regularizer，分别表征转换后的 hSI 的全局低秩和稀疏性以进行去噪。这种传统去噪的方法通常设计迭代优化和手动超参数微调，这使得它们再计算效率上很低，这对于高光谱图像去噪来说不够实用。

2.2 卷积神经网络

由于 CNN 已经证明了在 low-level 图像处理中的能力，DL 已经成为 HSI 去噪的关键方法，利用三维卷积 [1, 17] 及其变体的技术，在捕获局部空间-光谱相关性以进行 HSI 去噪方面发挥了至关重要的作用。NSSNN [8] 将注意力机制与递归单元相结合，提取 GSC 和非局部空间特征，取得了优越的去噪性能。然而，由于 CNN 的局部表示能力同时退化的图像中存在大量缺失信息，这些方法通常无法捕获足够的非局部信息，从而导致高光谱图像的 3D 性质没有得到有效利用，进而难以满足更高性能的去噪需求。

2.3 Transformer

由于注意力机制能够对长距离信息进行建模，transformer 也理所当然地被引入图像去噪。Translution-SNet [24] 使用十字形窗口通过合并水平和垂直线性块来利用空间相关性。然而，由于图像结构的破坏，这些方法通常会导致 HSI 的欠佳的空间谱 (spatial-spectral) 建模。此外，hsi 具有不独立同分布 (非 i.i.d) 噪声的光谱特征。如果没有进行选择性的关系构建，那么有害信息的存在，特别是来自污染严重的波段，会降低去噪性能。

2.4 状态空间模型

SSM 将序列数据映射到状态空间以捕获长距离的依赖关系，Mamba 是 SSM 的改进版本，在选择性扫描机制中引入了可学习参数，以数据依赖的方式选择相关信息。由于其卓越的计算效率和对远程依赖关系进行建模的能力，Mamba 在计算机视觉任务 [2, 20] 和自然语言处理 (NLP) [16] 中都表现出了独特的优势。然而，当前基于 Mamba 的方法不足以进行高光谱图像去噪，由于空间和光谱上下文像素都存在依赖关系。有鉴于此，通过考虑序列生成中的空间谱连续性来建模长距离空间谱相关性，将 SSM 应用于高光谱图像去噪。

3 本文方法

3.1 本文方法概述

本文提出的局部-长距离感知网络方法主要基于空间光谱的连续扫描以及注意力状态空间的应用，模型的整体架构图如图 2 所示。主要由六个阶段组成。首先通过特征提取器从高光谱图像中提取初始空间的光谱特征，将该特征分别传入到 ASSM 以及编码器中。在编码器中采用下采样和 3D 卷积从初始特征中提取多尺度特征，然后经过 6 组 SSCS Mamba Block 进行局部纹理和长距离空间光谱依赖的建模，再通过解码器使用带残差连接的上采样与 3D 卷积来重建特征，最后将解码器以及 ASSM 生成的特征进行解码生成去噪的高光谱图像。

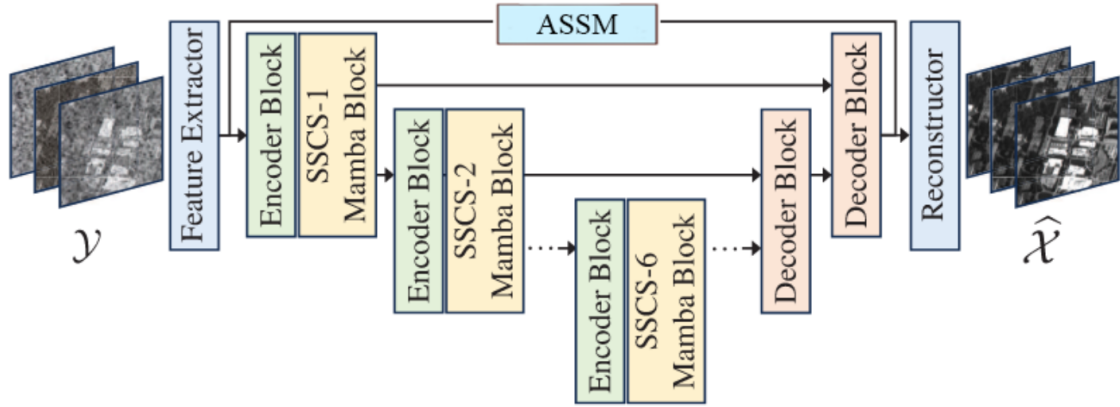


图 2. 局部-长距离感知网络架构图

3.2 空间光谱连续扫描

Mamba 应用于表现空间光谱相关的 3-D 高光谱数据时，产生了重大挑战。Mamba 的当前输出是由最后一个 token 和当前 Importing Token 的隐藏状态生成的，导致依赖关系以单向方式传播，如图 3 所示。在高光谱图像中，相邻的 token 通常具有相似性，反映出空间和光谱域的强依赖性，如图 4 所示。



图 3. Mamba 单向传播




图 4. 高光谱图像的相邻依赖

单向处理能导致在空间或光谱上相近的 token 在 1-D 序列非常远的位置找到，因此，定制一个扫描顺序来处理这些依赖关系是很有必要的。因此引入了用于 HSI 的 SSCS Mamba 模

块，如图 5所示，该模块将两个残差块和一个带有 SSCS 的双向 SSM 模块集成在一起，有效地捕获局部和全局空间光谱相关性和连续性。

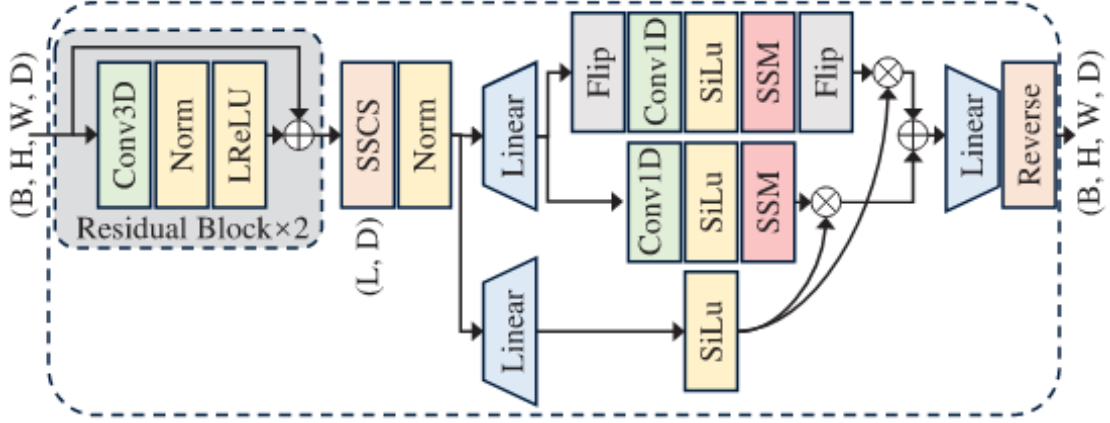


图 5. SSCS Mamba 模块

1. 残差块，通过在局部上下文中保持空间光谱相关性来提升局部纹理的检索。该模块包含一个 3-D 卷积、一个 instance normalization (IN 归一化) 和一个 leakyReLU，通过以下方式应用到输入特征

$$\mathcal{F}_{\text{res}} = \text{LReLU}(\text{Norm}(\text{Conv3D}(\mathcal{F}_{\text{in}}))) + \mathcal{F}_{\text{in}} \quad (1)$$

2. Spatial-Spectral Continuous Scan(SSCS) 空间光谱连续扫描：如图 6所示 SSCS 以己字型方案重新排列高光谱图像，以行-列-带顺序 (SSCS-1) 为例，SSCS 将输入特征 F 扫描成序列 S 。这种方法课确保在生成的序列中保持空间光谱连续性。此外，由于 HSI 中的每个像素都依赖于不同方向，包括行、列、波段周围像素的依赖关系。为了有效地对长距离的空间光谱依赖建模，创建了六种扫描方案，其中 BCR 分别代表波段，列，行。每种 SSCS 方案通常需要不同的 SSM 参数，增加方案的数量会导致参数数量显著增加，为了应对这种复杂性，将这六种方案分布在 SSUMamba 的六层中，并在每层中交替排列顺序。

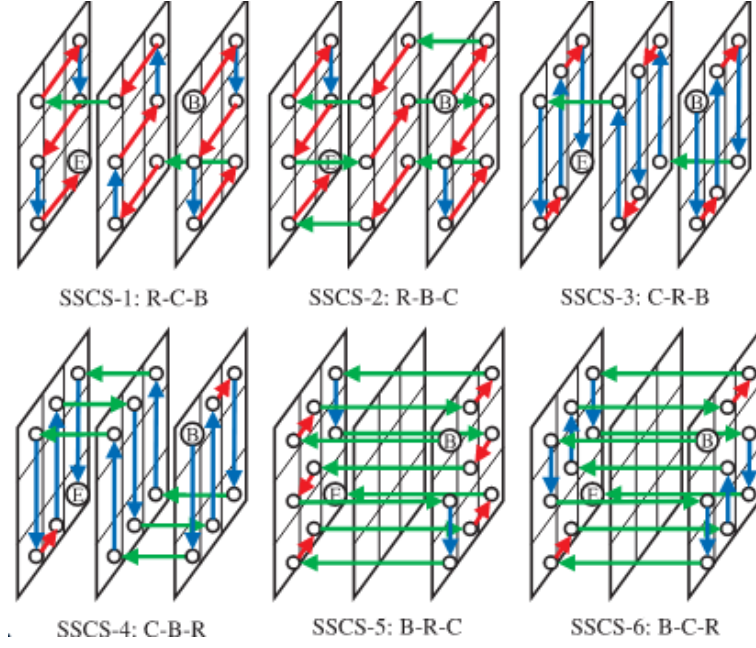


图 6. SSCS 扫描方案

3. 双向 SSM: 为了进一步增强双向依赖性, 双向 SSM 层翻转生成的序列促进向后扫描, 有效地利用 12 个方向的长距离空间光谱依赖, 该带有 SSCS 的双向 SSM 可以如下表示

$$\begin{aligned}
 S &= \text{SSCS}(\mathcal{F}) \\
 \mathcal{G} &= \text{SiLu}(\text{Linear}(\text{Norm}(S))) \\
 S_L &= \text{Linear}(\text{Norm}(S)) \\
 \mathcal{F}_f &= \text{SSM}(\text{SiLu}(\text{Conv1D}(S_L))) \\
 \mathcal{F}_b &= \text{Flip}(\text{SSM}(\text{SiLu}(\text{Conv1D}(\text{Flip}(S_L))))) \\
 \mathcal{F}_{\text{out}} &= \text{Reverse}(\text{Linear}(\mathcal{F}_f \odot \mathcal{G} + \mathcal{F}_b \odot \mathcal{G}))
 \end{aligned} \tag{2}$$

其中在 SSM 中的线性层和门 \mathcal{G} 的选择机制使模型能够选择性地传播或忽略依赖关系。这种机制有助于 SSM 在 HSI 去噪期间关注在低质序列中的有价值信息。最后, 使用 SSCS 的反向操作从双向 SSM 层中重塑输出特征。

3.3 注意力状态空间

因果扫描就是如果将图像展开成 1D 序列, 那么在展开序列中的第 i 个像素只能利用到它的前 $i-1$ 个像素, 而无法用到序列之后的其他像素。对于高光谱图像的某一个像素, 这种因果扫描存在明显的局限性, 它忽视了每一个 token 的丰富上下文信息。如图 7 所示, 其中左图为普通的顺序扫描, 而右图为该方法的注意力扫描。

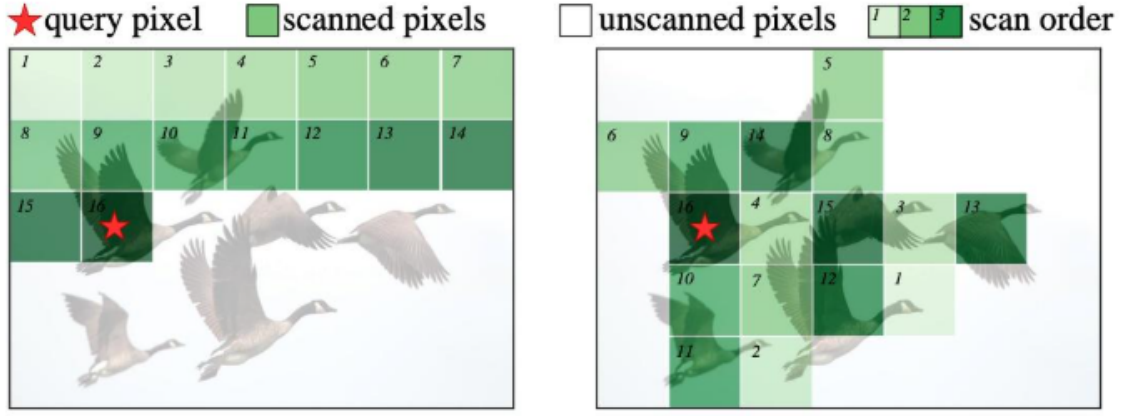


图 7. 顺序与注意力扫描

因此为了应对在 SSCS 上对于局部特征扫描的缺失问题，本文引入了注意力状态空间模块（Attentive State Space Module, ASSM）如图 8 所示，其进一步包括了注意力状态空间方程（Attentive State-space Equation, ASE）和语义引导邻域（Semantic Guided Neighboring, SGN）

给定输入特征 $\mathbf{x} \in \mathbb{R}^{H \times W \times C}$ ，其中 H 和 W 分别是高度和宽度， C 是通道维度，首先对 x 应用位置编码以保留原始结构信息。之后，使用 SGN 将 2D 图像展开成 1D 序列，以便后续的 ASE 建模。最后，另一个 SGN 作为之前操作的逆操作，将序列重新折叠回图像，然后通过线性投影得到模块输出。如图 8 中 a 所示。




图 8. 注意力状态空间模块

1. ASE: 为了将 Attention 与 SSM 相关联，目标修改输出矩阵 C 以便全局查询图像中的相关像素。为此提出 ASE，它基于 Mamba 的原始状态空间方程，但具有非因果性质。如图 8 中 b 所示，提出的 ASE 将提示（prompts）纳入到 C 中，这些提示学习代表具有相似语义的一定像素集合，以补充未扫描像素缺失的信息。具体来说，首先构建提示池 P 来包含一系列可学习的典型 prompts。对于 P 的参数化，采用低秩解耦以提高参数效率：

$$\mathcal{P} = \mathbf{M}\mathbf{N}, \mathbf{M} \in \mathbb{R}^{T \times r}, \mathbf{N} \in \mathbb{R}^{r \times d} \quad (3)$$

其中 N 在不同块之间共享， M 是块特定的， r 是内部秩，且 $r \ll \min\{T, d\}$ 。这里使用低秩解耦的主要思想是希望不同的块共享类似的特征空间，即 N 是共享的，而共享特征的组合系数可以因不同的 block 而异，即 M 是特定的。之后，开发路由策略从 P 中选择以获得 L 个实例特定的提示 $\mathbf{P} \in \mathbb{R}^{L \times d}$ ，这些将被添加到 C 中以包含未扫描像素的信息。具体来说，给定展开的输入特征 $x' \in \mathbb{R}^{L \times C}$ ，使用线性层将 x' 的通道维度从 C 投影到 T ，然后通过 LogSoftmax 预测对数概率，这表示 P 中每个提示被 x'_i 采样的

概率, $i = 1, 2, \dots, L$ 。之后, 在对数概率上引入 gumbel-softmax 技巧, 以允许可微分的提示选择操作, 以获得路由矩阵 $\mathbf{R} \in \mathbb{R}^{L \times T}$ 。然后, 通过矩阵乘法生成实例特定的提示, 即 $\mathbf{P} = \mathbf{R}\mathbf{P}$ 。最后, 通过残差加法将 P 纳入 C 形成所提出的注意力状态空间方程:

$$\begin{aligned} h_i &= \bar{\mathbf{A}}h_{i-1} + \bar{\mathbf{B}}x_i, \\ y_i &= (\mathbf{C} + \mathbf{P})h_i + \mathbf{D}x_i \end{aligned} \quad (4)$$

通过这种方式学习到的提示能够在整个图像中查询像素, 获得类似注意力的能力。通过注入代表相似像素集合的意识, ASE 可以有效缓解对未扫描像素的首先感知, 同时由于只允许单一方向扫描, 消除了现有方法中多方向扫描的高计算成本与冗余。

2. SGN: 在基于 Mamba 的图像恢复方法中, 由于 Mamba 自身的因果扫描特性, 存在长距离衰减这一不利影响。具体来说, 原始图像里相距较远的像素在展开的序列中往往依旧彼此疏离, 这就使得查询像素难以充分利用那些已被扫描到的、空间上虽远但内容相似的像素信息。而 SGN 能有效解决这一问题, 如图 8 中 c 所示。与自回归语言建模不同, 图像去噪是一个非因果任务, 所有的像素都是一次性可见的, 因此可以重新界定 token 邻域, 让语义相近的 token 在空间上更为接近。

遵循这一思路, 首先明确每个像素的语义标签, 而在 ASE 中的路由矩阵 R 已经学习到了每个像素的提示类别, 因此借助种种语义信息对图像重构, 也就是 SGN-unfold 将具有第 i 个提示类别的像素整合为第 i 个与一组, 然后依据类别值 i 对不同组进行组合, 进而生成语义临近序列。在此基础上, 将这个序列输入到 ASE 中, 以进行状态空间建模操作。最终运用 SGN-fold 作为 SGN-unfold 的逆变换方法, 将语义空间序列重新塑造回空间特征图以获得最终的输出结果。

3.4 损失函数定义

设 \mathcal{X} 为 $H \times W$ 像素的 $H \times W$ 波段的干高光谱图像, 当加入噪声 \mathcal{E} , 例如高斯噪声、脉冲噪声、条纹噪声, 此时的 HSI \mathcal{Y} 用数学表示如下。

$$\mathcal{Y} = \mathcal{X} + \mathcal{E} \quad (5)$$

本局部-长距离感知网络旨在学习从 \mathcal{Y} 到 \mathcal{X} 的映射以进行降噪, 损失函数定义为最小化在真值 HSI X 与预测 HSI \hat{X} 之间的 L2 距离, N 代表每次迭代的 batch size。

$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N \left\| \hat{X}_i - X_i \right\|_F^2 \quad (6)$$

4 复现细节

4.1 与已有开源代码对比

本文首先复现了用于高光谱图像去噪的空间光谱 SSUMamba 模型, 其空间光谱连续扫描方式虽然可以有效提升模型对长距离空间光谱的依赖, 但由于其扫描的本质仍旧为 2D 图像展开为 1D 序列的因果扫描, 这种因果扫描得到的 1D 序列仍会存在局部遗忘问题, 对于记

忆较长的序列所需要的大的 SSM 隐层维度也会导致通道冗余现象的发生。因此本文采用注意力状态空间模块 (ASSM) 对 SSUMamba 进行改进, 通过这种非因果扫描促进模型学习到高光谱图像的局部信息特征, 这有助于进一步提升图像去噪能力。

4.2 实验环境搭建

本节将详细介绍实验环境的细节。首先对于训练与测试的数据集进行介绍。然后说明本次实验的详细环境配置, 包括硬件环境、参数优化、评价指标的介绍。

4.2.1 数据集

使用 ICVL 数据集来验证所提出方法的有效性, 由 pecim PS Kappa DX4 高光谱相机拍摄。这些高光谱图像的分辨率为 1392×1300 像素, 覆盖 400 至 700 nm 的 31 个光谱波段。选取 100 张作为训练集进行训练, 将图像分成大小为 $64 \times 64 \times 31$ 的 patch, 通过随机翻转、裁剪、调整大小来增强训练集。测试集由另外 50 张高光谱图像组成。

4.2.2 实验细节与设置

1. 实验设置: 由于真实世界的噪声通常由非独立同分布的特性, 因此使用高斯噪声进行加噪, 在 $\sigma \in [0, 95]$ 的范围内改变标准差, 实验在 Intel(R) Xeon(R) CPU E5-2690 v4@2.60GHz、8 张 Tesla P100-PCIE-16GB, CUDA 版本 12.1 的服务器上进行。
2. 参数优化: 本文的局部-长距离感知网络是基于 Pytorch 框架实现的, 使用 Adam 优化器优化训练过程, 学习率设置为 $3e-4$, batch_size 设置为 5, 经历 45 个 epoch 的训练。
3. 评价指标: 为了定量评估去噪性能, 采用峰值信噪比 (PSNR)、结构相似性指数 (SSIM)、光谱角制图 (SAM) 三种评价指标。更高的 PSNR、SSIM 表明更好的去噪效果, 更小的 SAM 表明更优越的性能。

4.3 创新点

本文的主要贡献可以总结如下:

1. 引入了注意力状态空间模块, 能够赋予模型非因果建模能力, 通过这种注意力机制, 能够有效改善 SSUMamba 在高光谱去噪任务中的因果建模的局限性问题。
2. 针对高光谱图像去噪任务提出了一种局部-长距离感知网络, 能够充分捕获高光谱图像的上下文信息以提高去噪能力。
3. 在公开的高光谱图像数据集上的实验结果表明, 所提方法在去噪性能上优于基准模型方法。
4. 源码中没有关于测试结果的可视化分析, 本文编写了光谱反射率曲线及测试结果的可视化代码以供实验结果的分析。

5 实验结果分析

本节对实验结果进行分析，主要包括两个部分，第一部分是消融实验，分析不同模块对于去噪任务的贡献；第二部分采用标准差范围为 $[0,95]$ 的高斯噪声加噪的高光谱图像进行测试，与几种先进方法进行对比实验。

5.1 消融实验

本节评估局部-长距离感知网络中不同模块对去噪效果的贡献，包括 SSCS 与 ASSM 在数据集上的实验结果，采用 PSNR、SSIM、SAM 进行评估。评估结果如表 1 所示，其中粗体代表在数据集上该评价指标达到最优性能。可以发现，本文提出的局部-长距离感知网络具有一定的去噪性能提升。

方法	PSNR \uparrow	SSIM \uparrow	SAM \downarrow
SSCS	44.73	.9832	.0482
SSCS&ASSM	44.82	.9837	.0465

表 1. 局部-长距离感知网络中不同模块的性能贡献

通过对 ICVL 测试集上与真值取差值的绝对值得到光谱反射率曲线，如图 9 所示，可以发现本文 SSCS&ASSM 方法整体的光谱反射率低于纯 SSCS 方法，因此在高光谱图像去噪上具有更高的鲁棒性。




图 9. 在 ICVL 上测试集上的光谱反射率

5.2 对比实验

本节进行本文所提方法与几种先进方法的性能比较，包括 TRQ3D [22], NSSNN [8], MAC-Net [25]，这些方法的具体网络结构及参数设置均可在相应的参考文献中找到，采用 PSNR、

SSIM、SAM 进行评估，在 ICVL 数据集上的评估结果如表 2 所示。

方法	PSNR \uparrow	SSIM \uparrow	SAM \downarrow
Noisy	13.21	.0841	.9124
MAC-Net	41.24	.9577	.0841
NSSNN	44.42	.9809	.0524
TRQ3D	43.54	.9806	.0523
SSCS&ASSM	44.82	.9837	.0465

表 2. 在 ICVL 数据集上的评估结果

选取 ICVL 测试集的一张图像进行可视化，由于 ICVL 的高光谱图像具有 31 个光谱波段，无法直接可视化成 RGB 图像，因此本文选取第 10、20、30 个波段进行组合生成伪彩色图像，实验结果如图 10 所示。其中左图为加噪图像，中间图为去噪图像，右图为真实图像。可以发现本文方法具有较好的去噪性能。



图 10. 在 ICVL 测试集上的去噪结果

6 总结与展望

针对目前在高光谱图像去噪中在长距离空间光谱上建模的复杂度过高问题，本文提出一种局部-长距离感知网络。通过 SSCS 的六种扫描方式对长距离特征的捕获以及 ASSM 通过注意力机制对局部上下文信息的融合，有效提升模型在高光谱图像上建立更可靠的全局依赖关系，提高模型对于更复杂噪声的鲁棒性。在公开数据集上的实验表明，本文提出的方法有效提升了去噪性能。

在未来的研究中，高光谱图像的去噪的准确率及效率仍有提升空间。虽然本文方法提升了去噪的准确度，但同时也增加了模型的复杂度。未来可以考虑对模型进行简化，比如减少扫描次数，采用效果最佳的扫描方法。或者考虑在线性扫描时同时进行长距离的扫描以及局部上下文的扫描以减小时间开支，提高模型的效率。

参考文献

- [1] Yi Chang, Luxin Yan, Houzhang Fang, Sheng Zhong, and Wenshan Liao. Hsi-denet: Hyperspectral image restoration via convolutional neural network. *IEEE Transactions on*

- Geoscience and Remote Sensing*, 57(2):667–682, 2018.
- [2] Guo Chen, Yifei Huang, Jilan Xu, Baoqi Pei, Zhe Chen, Zhiqi Li, Jiahao Wang, Kunchang Li, Tong Lu, and Limin Wang. Video mamba suite: State space model as a versatile alternative for video understanding. *arXiv preprint arXiv:2403.09626*, 2024.
 - [3] Hongyu Chen, Guangyi Yang, and Hongyan Zhang. Hider: A hyperspectral image denoising transformer with spatial–spectral constraints for hybrid noise removal. *IEEE Transactions on Neural Networks and Learning Systems*, 2022.
 - [4] Lulu Chen, Yongqiang Zhao, Jiabin Yao, Jiabin Chen, Ning Li, Jonathan Cheung-Wai Chan, and Seong G Kong. Object tracking in hyperspectral-oriented video with fast spatial-spectral features. *Remote Sensing*, 13(10):1922, 2021.
 - [5] Michele Dalponte, Hans Ole Ørka, Terje Gobakken, Damiano Gianelle, and Erik Næsset. Tree species classification in boreal forests with hyperspectral data. *IEEE Transactions on Geoscience and Remote Sensing*, 51(5):2632–2645, 2012.
 - [6] Michael D Farrell and Russell M Mersereau. On the impact of pca dimension reduction for hyperspectral detection of difficult targets. *IEEE Geoscience and Remote Sensing Letters*, 2(2):192–195, 2005.
 - [7] Guanyiman Fu, Fengchao Xiong, Jianfeng Lu, and Jun Zhou. Ssumamba: Spatial-spectral selective state space model for hyperspectral image denoising. *IEEE Transactions on Geoscience and Remote Sensing*, 2024.
 - [8] Guanyiman Fu, Fengchao Xiong, Jianfeng Lu, Jun Zhou, and Yuntao Qian. Nonlocal spatial–spectral neural network for hyperspectral image denoising. *IEEE Transactions on Geoscience and Remote Sensing*, 60:1–16, 2022.
 - [9] Albert Gu and Tri Dao. Mamba: Linear-time sequence modeling with selective state spaces. *arXiv preprint arXiv:2312.00752*, 2023.
 - [10] Albert Gu, Karan Goel, and Christopher Ré. Efficiently modeling long sequences with structured state spaces. *arXiv preprint arXiv:2111.00396*, 2021.
 - [11] Hang Guo, Yong Guo, Yaohua Zha, Yulun Zhang, Wenbo Li, Tao Dai, Shu-Tao Xia, and Yawei Li. Mambairv2: Attentive state space restoration. *arXiv preprint arXiv:2411.15269*, 2024.
 - [12] Kate S He, Duccio Rocchini, Markus Neteler, and Harini Nagendra. Benefits of hyperspectral remote sensing for tracking plant invasions. *Diversity and Distributions*, 17(3):381–392, 2011.
 - [13] Vincent Tao Hu, Stefan Andreas Baumann, Ming Gui, Olga Grebenkova, Pingchuan Ma, Johannes Fischer, and Björn Ommer. Zigma: A dit-style zigzag mamba diffusion model. In *European Conference on Computer Vision*, pages 148–166. Springer, 2025.

- [14] Zeqiang Lai, Chenggang Yan, and Ying Fu. Hybrid spectral denoising transformer with guided attention. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 13065–13075, 2023.
- [15] Miaoyu Li, Ying Fu, and Yulun Zhang. Spatial-spectral transformer for hyperspectral image denoising. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pages 1368–1376, 2023.
- [16] Opher Lieber, Barak Lenz, Hofit Bata, Gal Cohen, Jhonathan Osin, Itay Dalmedigos, Erez Safahi, Shaked Meirom, Yonatan Belinkov, Shai Shalev-Shwartz, et al. Jamba: A hybrid transformer-mamba language model. *arXiv preprint arXiv:2403.19887*, 2024.
- [17] Wei Liu and Joonwhoan Lee. A 3-d atrous convolution neural network for hyperspectral image denoising. *IEEE transactions on geoscience and remote sensing*, 57(8):5701–5715, 2019.
- [18] Yang Liu, Jiahua Xiao, Yu Guo, Peilin Jiang, Haiwei Yang, and Fei Wang. Hsidmamba: Exploring bidirectional state-space models for hyperspectral denoising. *arXiv preprint arXiv:2404.09697*, 2024.
- [19] Fulin Luo, Tianyuan Zhou, Jiamin Liu, Tan Guo, Xiuwen Gong, and Jinchang Ren. Multi-scale diff-changed feature fusion network for hyperspectral image change detection. *IEEE Transactions on Geoscience and Remote Sensing*, 61:1–13, 2023.
- [20] Jun Ma, Feifei Li, and Bo Wang. U-mamba: Enhancing long-range dependency for biomedical image segmentation. *arXiv preprint arXiv:2401.04722*, 2024.
- [21] Dimitris Manolakis and Gary Shaw. Detection algorithms for hyperspectral imaging applications. *IEEE signal processing magazine*, 19(1):29–43, 2002.
- [22] Li Pang, Weizhen Gu, and Xiangyong Cao. Trq3dnet: A 3d quasi-recurrent and transformer based network for hyperspectral image denoising. *Remote Sensing*, 14(18):4598, 2022.
- [23] Bea Thai and Glenn Healey. Invariant subpixel material detection in hyperspectral imagery. *IEEE Transactions on Geoscience and Remote Sensing*, 40(3):599–608, 2002.
- [24] Chengjun Wang, Miao Zhong Xu, Yonghua Jiang, Guo Zhang, Hao Cui, Litao Li, and Da Li. Translution-snet: A semisupervised hyperspectral image stripe noise removal based on transformer and cnn. *IEEE Transactions on Geoscience and Remote Sensing*, 60:1–14, 2022.
- [25] Fengchao Xiong, Jun Zhou, Qinling Zhao, Jianfeng Lu, and Yuntao Qian. Mac-net: Model-aided nonlocal neural network for hyperspectral image denoising. *IEEE Transactions on Geoscience and Remote Sensing*, 60:1–14, 2021.

- [26] Hao Zhang, Ting-Zhu Huang, Xi-Le Zhao, Wei He, Jae Kyu Choi, and Yu-Bang Zheng. Hyperspectral image denoising: Reconciling sparse and low-tensor-ring-rank priors in the transformed domain. *IEEE Transactions on Geoscience and Remote Sensing*, 61:1–13, 2023.
- [27] Lianghui Zhu, Bencheng Liao, Qian Zhang, Xinlong Wang, Wenyu Liu, and Xinggang Wang. Vision mamba: Efficient visual representation learning with bidirectional state space model. *arXiv preprint arXiv:2401.09417*, 2024.